PROJET DATA SCIENCE · APPROCHE ACTUARIELLE

Coûts d'assurance maladie : quels facteurs, quelle prédiction ?

Analyse statistique et modélisation de 1 337 assurés : qualité des données, exploration, tests d'hypothèses, comparaison de 8 modèles, interprétation SHAP et audit d'équité.

Rapport généré automatiquement le 2026-10-26 · commit `51db377` · données SHA-256 `505c1cbc2e63…` · Python 3.12.12 · seed 42

Résumé exécutif

Variance expliquée (test)

R² 0,922

Lasso, sur des assurés jamais vus

Erreur absolue moyenne

1 992 $

RMSE 3 345 $ contre 12 013 $ pour la baseline

Fumeur vs non-fumeur

×3,8

sur le coût moyen annuel

Fumeur obèse vs non-fumeur

+33 117 $

par an (41 558 $ contre 8 441 $)

Question. Quels facteurs expliquent les frais médicaux annuels d'un assuré, et comment les prédire de façon fiable, interprétable et équitable ?

- **Trois facteurs suffisent à expliquer l'essentiel** : le tabagisme, l'âge et l'IMC (en ordre d'importance SHAP). Le sexe et la région pèsent moins de 297 $ en moyenne.
- **Le tabagisme et l'obésité interagissent** : au-delà d'un IMC de 30, le coût d'un fumeur bondit (≈ 21 363 $ → 41 558 $), alors que l'IMC ne change presque rien pour un non-fumeur.
- **Un modèle linéaire transparent égale le boosting** quand il reçoit ces interactions : Lasso (R² 0,922) est à égalité statistique avec XGBoost et LightGBM, avec des coefficients auditables et un modèle de 2,1 Ko.
- **Limite principale** : environ 3,4 % des assurés subissent un « choc » de coût que les 6 variables disponibles n'expliquent pas. Il faudrait des données médicales pour aller plus loin.
- **Équité** : le modèle se trompe à peu près autant pour les hommes et les femmes et selon les régions. Une tarification unisexe (obligatoire dans l'UE) ne coûte rien en précision. Point de vigilance : la calibration des plus jeunes.

1. Données et qualité

Medical Cost Personal Dataset (B. Lantz, *Machine Learning with R* ; diffusion Kaggle, licence ODbL) : 1 338 assurés américains, 6 variables explicatives (âge, sexe, IMC, enfants, tabagisme, région) et la cible `charges` (frais médicaux annuels, USD). Données **simulées** à partir de statistiques démographiques : les conclusions illustrent une méthode, pas un portefeuille réel. Source téléchargée et vérifiée par empreinte : https://raw.githubusercontent.com/stedy/Machine-Learning-with-R-datasets/master/insurance.csv.

Audit

Contrôle	Résultat
Doublons exacts	1
Valeurs manquantes	0
Modalités inattendues / valeurs impossibles	0 / 0
IMC atypiques (IQR)	9 : plausibles (obésité morbide), conservés
Coûts au-delà de Q3 + 1,5·IQR (34 489 $)	139, dont 97,8 % de fumeurs (contre 20,5 % au global)

Nettoyage journalisé

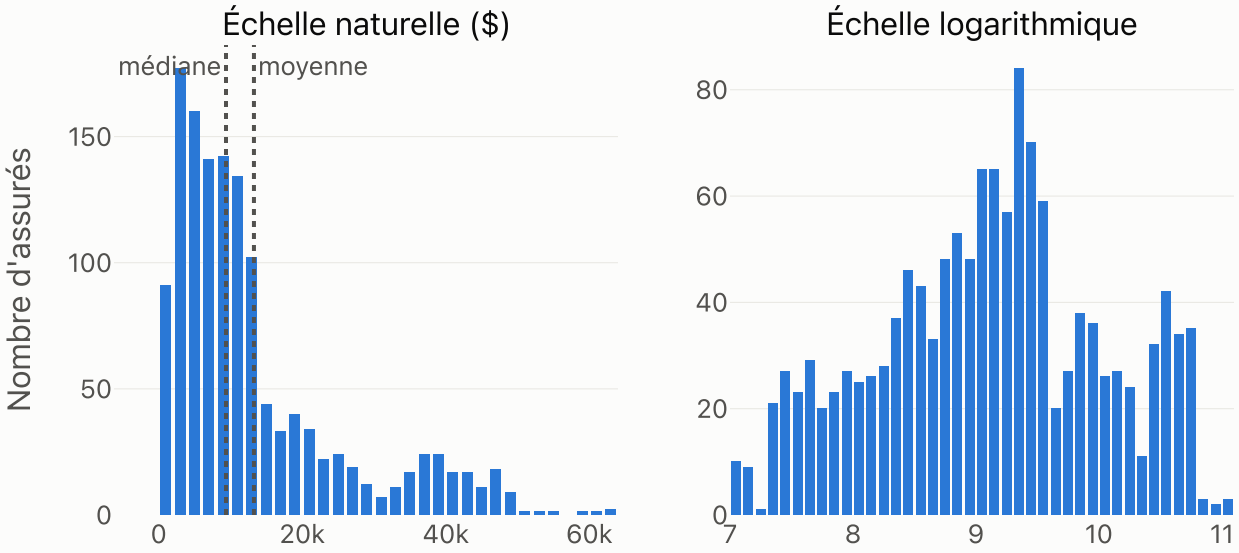
Action	Lignes retirées	Justification
Normalisation des types et des libellés	0	Libellés en minuscules sans espaces ; conversion numérique stricte.
Suppression des doublons exacts	1	Sans identifiant, deux lignes identiques au centime près sur les 7 variables sont presque certainement une double saisie : la garder sur-pondérerait ce profil.
Suppression des lignes incomplètes	0	Aucune imputation : la part de manquants est nulle ou négligeable, et imputer la cible ou ses déterminants principaux introduirait un biais.
Exclusion des valeurs impossibles	0	Hors bornes de plausibilité ou modalité inconnue : erreurs de saisie.
Conservation des valeurs extrêmes de coûts	0	Les coûts élevés sont le risque que l'assureur couvre. Les retirer sous-estimerait la prime pure. Ils sont traités par la modélisation (cible log, GLM Gamma, métriques robustes).

Les coûts extrêmes sont **conservés** : ils ne sont pas des erreurs mais le risque que l'assureur couvre. Les retirer ferait baisser artificiellement la prime pure.

2. Analyse exploratoire

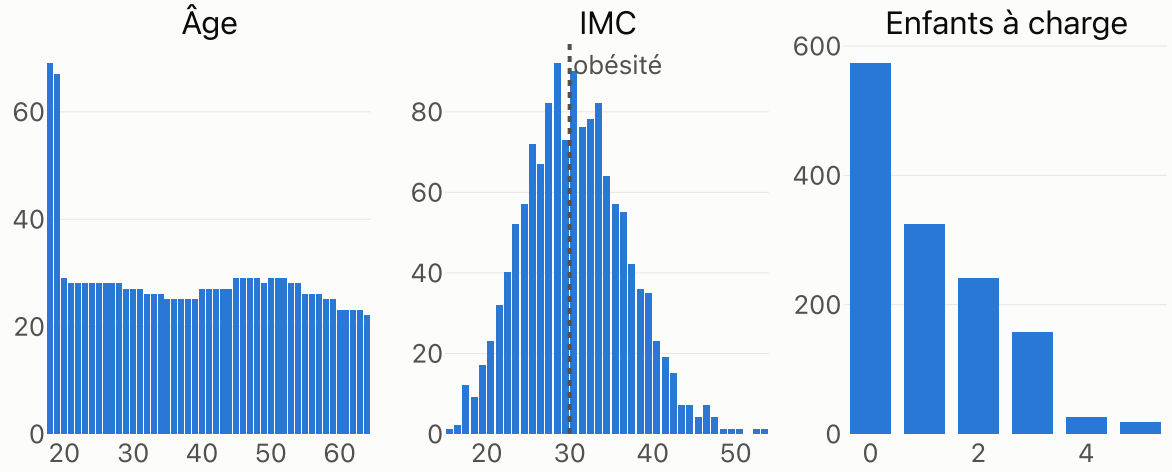
Univariée

Distribution des coûts annuels



Les coûts sont fortement asymétriques à droite (skewness 1,51) : la moyenne (13 279 $) dépasse nettement la médiane (9 386 $), et les 10 % d'assurés les plus coûteux concentrent 32% de la charge totale. Après passage au logarithme, la distribution devient quasi symétrique (skewness -0,09) mais reste multimodale, signe de sous-populations distinctes. Cette forme motive une cible log, le GLM Gamma à lien log, et le suivi de la MAE en plus de la RMSE.

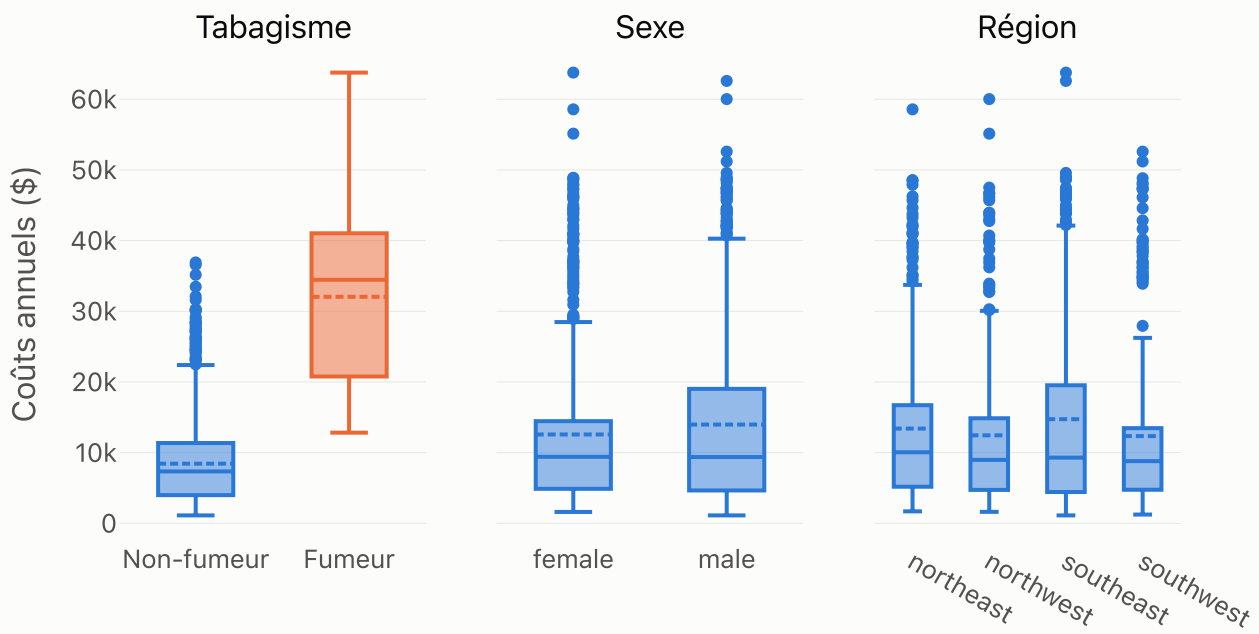
Distribution des variables numériques



L'âge est quasi uniforme entre 18 et 64 ans, avec un pic à 18-19 ans (10,2% des assurés), artefact probable de la simulation. L'IMC suit une loi proche de la normale (moyenne 30,7) ; 53% des assurés sont obèses (IMC ≥ 30). Le nombre d'enfants décroît de 0 à 5. Les variables catégorielles sont équilibrées (hommes 50%, régions de 24 à 27 %), sauf le tabagisme : 20% de fumeurs.

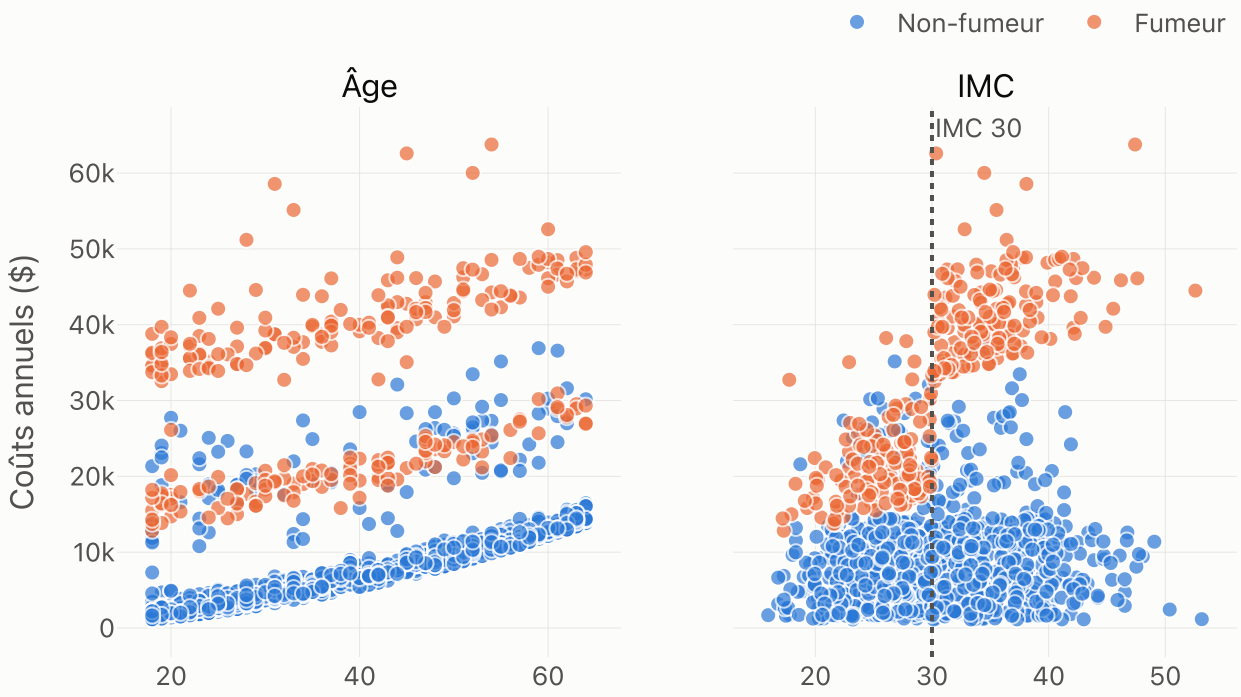
Bivariée

Coûts selon les variables catégorielles



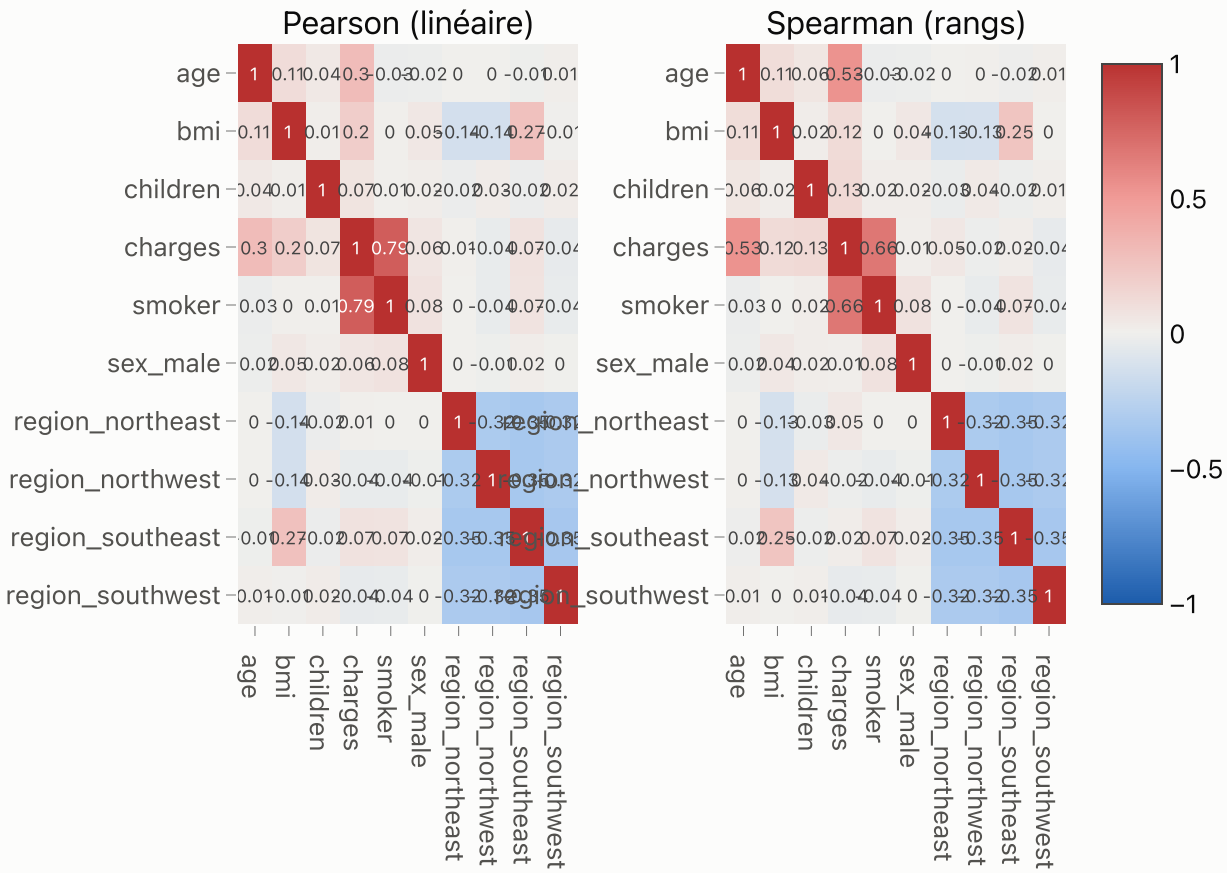
Le tabagisme domine : un fumeur coûte en moyenne 32 050 $ contre 8 441 $ pour un non-fumeur, soit ×3,8. Les écarts par sexe (hommes 13 975 $, femmes 12 570 $) et par région (maximum : southeast, 14 735 $) sont modestes. La phase 4 teste s'ils sont significatifs et s'ils persistent une fois le tabagisme pris en compte (le sud-est compte plus de fumeurs et d'obèses).

Coûts en fonction de l'âge et de l'IMC



Les coûts croissent avec l'âge de façon régulière (≈ 267 $ par année chez les non-fumeurs), en trois bandes parallèles : non-fumeurs, fumeurs non obèses et fumeurs obèses. L'IMC n'a presque pas d'effet chez les non-fumeurs (+879 $ au-delà de 30) mais crée une rupture chez les fumeurs (+20 195 $). C'est une **interaction** : l'effet de l'IMC dépend du tabagisme. Un modèle additif ne peut pas la capturer sans un terme dédié (phase 5).

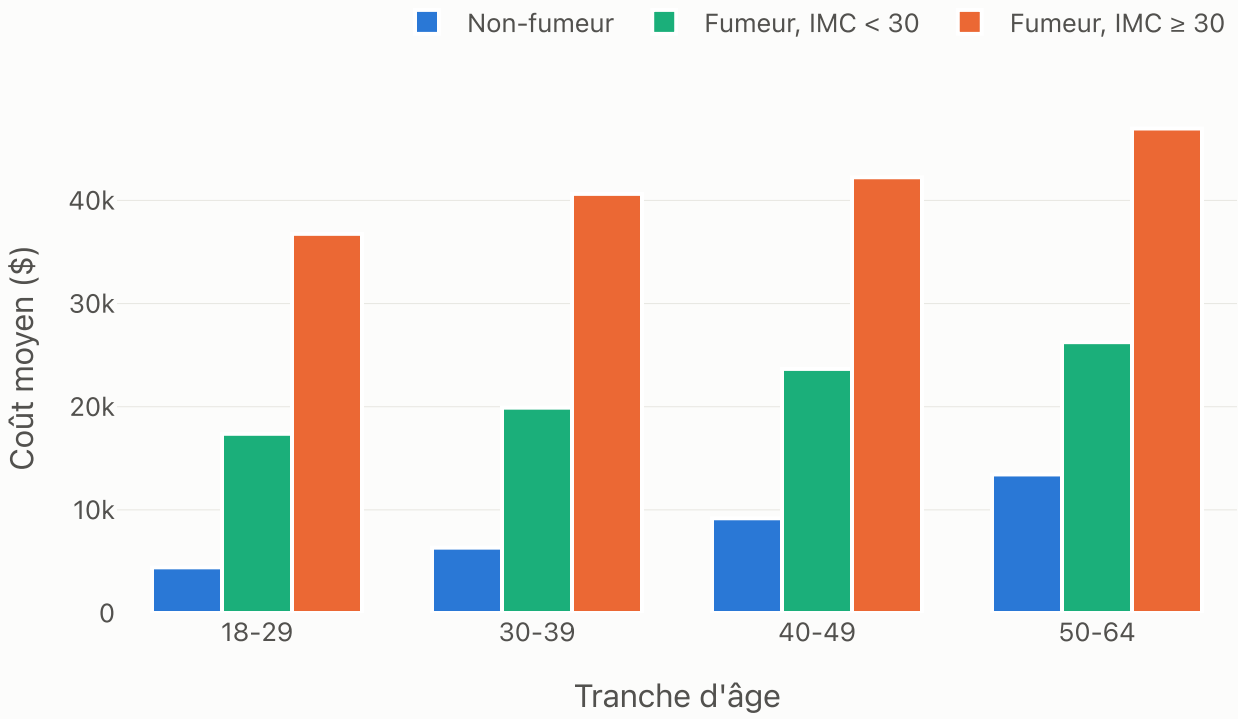
Matrices de corrélation (variables encodées)



Corrélation avec les coûts : tabagisme r = 0,79, âge r = 0,30, IMC r = 0,20, les autres variables sont proches de 0. En rangs (Spearman), l'âge devient le premier facteur (ρ = 0,53) : il ordonne régulièrement les coûts, tandis que le tabagisme crée les écarts les plus importants en montant. Les variables explicatives sont peu corrélées entre elles (VIF max 1,60, très en dessous du seuil usuel de 5) : il n'y a pas de multicolinéarité à traiter pour les modèles linéaires.

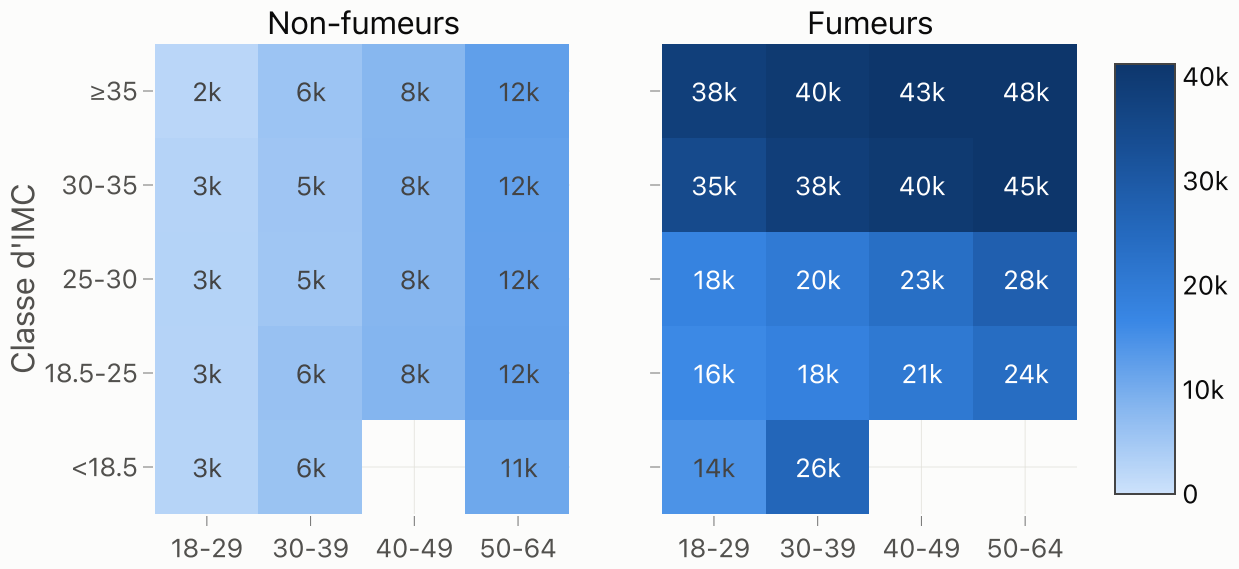
Multivariée

Coût moyen par segment de risque et âge



En combinant trois variables, on obtient une segmentation tarifaire lisible : non-fumeurs (8 441 $ en moyenne, n = 1063), fumeurs non obèses (21 363 $, n = 129) et fumeurs obèses (41 558 $, n = 145). Dans chaque segment, l'âge ajoute un gradient régulier. Ce couple tabagisme × obésité, puis l'âge, structure la suite de la modélisation.

Coût médian par IMC × âge, selon le tabagisme



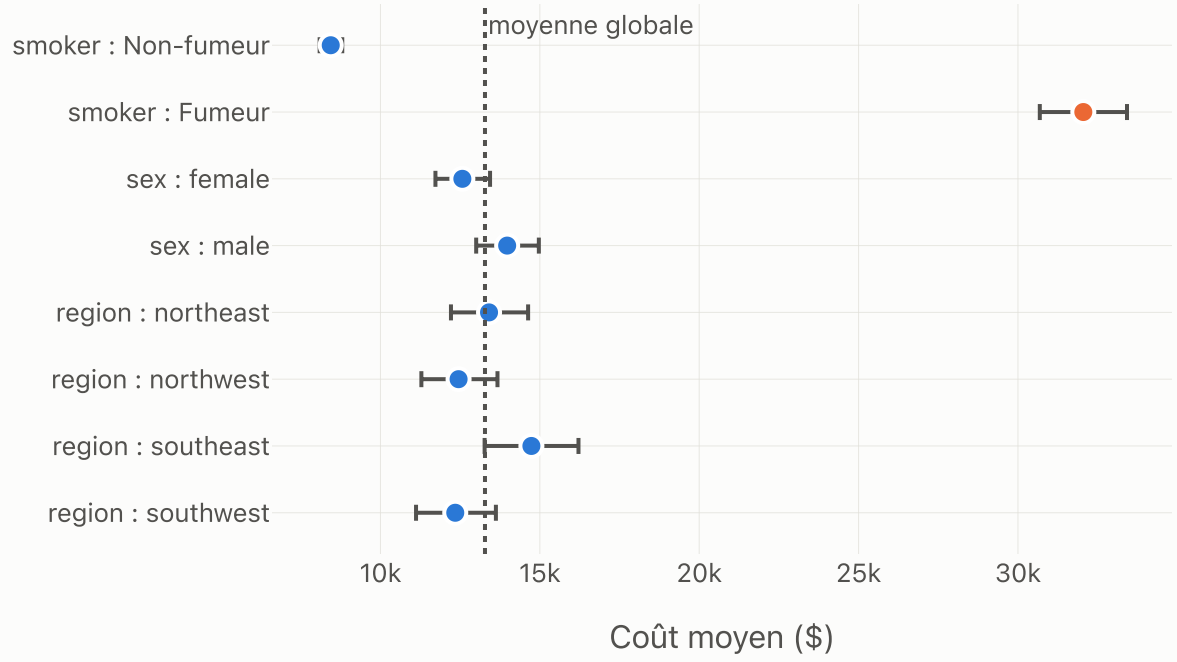
La carte de chaleur confirme l'interaction à trois variables. Chez les non-fumeurs, la couleur varie surtout de gauche à droite (effet de l'âge). Chez les fumeurs, elle bascule nettement au-dessus de 30 d'IMC, et ce quel que soit l'âge. Un modèle à arbres capture cette structure automatiquement ; un modèle linéaire ou un GLM doit la recevoir comme variable construite.

3. Statistiques inférentielles

Démarche : **vérifier les hypothèses avant de tester** (Shapiro-Wilk pour la normalité, Levene pour l'égalité des variances), retenir le test dont les hypothèses tiennent, et rapporter **tailles d'effet et intervalles de confiance**, pas seulement des p-values. Correction de Holm pour les tests multiples ; tests F partiels sur log(coûts) pour contrôler la confusion.

Question	Test retenu	p	Taille d'effet
Fumeurs vs non-fumeurs	Mann-Whitney (+ Welch, bootstrap)	< 0,001	g = 3,16, r_{rb} = 0,95 (fort)
Hommes vs femmes (brut)	Mann-Whitney	0,694	g = 0,12 (négligeable)
Hommes vs femmes (à profil égal)	F partiel, OLS log	< 0,001	$\eta^2 p$ = 0,010
Régions (brut)	Kruskal-Wallis / Alexander-Govern	0,202 / 0,053	η^2 = 0,007 (négligeable)
Régions (à profil égal)	F partiel, OLS log	< 0,001	$\eta^2 p$ = 0,019
Nombre d'enfants	Kruskal-Wallis	< 0,001	ε^2 = 0,018
Tabagisme × région	χ^2 d'indépendance	0,064	V = 0,07
Tabagisme × sexe	χ^2 d'indépendance	0,006	V = 0,07

Coût moyen par groupe, IC 95 % bootstrap (10 000 tirages)



Conclusions

- Hypothèses : les coûts ne sont normaux dans aucun groupe (Shapiro-Wilk p min = 1,5e-28) et les variances sont hétérogènes (Levene p < 0,001). Le t de Student et l'ANOVA classique sont donc fournis à titre indicatif ; les conclusions reposent sur Welch, Mann-Whitney, Kruskal-Wallis, Alexander-Govern et le bootstrap.
- Tabagisme : les fumeurs coûtent en moyenne 23 610 $ de plus (IC 95 % bootstrap [22 186 ; 25 039] $). Mann-Whitney p < 0,001, corrélation rang-bisériale 0,95, g de Hedges 3,16 : effet très fort, résultat central de l'étude.
- Sexe : écart brut de 1 405 $ en faveur des femmes (Welch p = 0,034, mais Mann-Whitney p = 0,694), effet négligeable. Cet écart brut vient surtout de la plus forte proportion de fumeurs chez les hommes. À profil égal (âge, IMC, enfants, tabagisme), le sens s'inverse : -8,3% pour un homme (p < 0,001, η^2 partiel 0,010). L'effet est détectable mais faible, et le sexe est un critère tarifaire interdit dans l'UE (arrêt Test-Achats, 2011).
- Région : ANOVA p = 0,033 mais Kruskal-Wallis p = 0,202 et Alexander-Govern p = 0,053 (η^2 = 0,007, effet négligeable) : pas d'écart brut robuste. Ajusté des autres facteurs (p < 0,001, η^2 partiel 0,019), on observe un effet modéré par rapport au nord-est : northwest -5,8%, southeast -13,9%, southwest -12,8%.
- Tabagisme × région : χ^2 p = 0,064, V de Cramér 0,07. Tabagisme × sexe : χ^2 p = 0,006, V = 0,07 (effectifs attendus tous ≥ 5, condition du χ^2 respectée). Dans les deux cas, l'association est faible.
- Corrélations : âge r = 0,30 (IC 95 % [0,25 ; 0,35]), IMC r = 0,20 (IC 95 % [0,15 ; 0,25]).
- Tests multiples : après correction de Holm sur les 8 tests de la famille, restent significatifs au seuil de 5 % : smoker (Mann-Whitney), children (Kruskal-Wallis), sex x smoker (chi2), sex | controls (F), region | controls (F).
- Un p-value très faible ne mesure pas l'ampleur d'un effet. Les tailles d'effet montrent que le tabagisme écrase tous les autres facteurs catégoriels.

4. Feature engineering

Tout est encapsulé dans un pipeline scikit-learn (aucune fuite entre plis, transformations identiques en production) : indicateur d'obésité (IMC ≥ 30, seuil OMS), interactions `fumeur × obèse`, `IMC × fumeur`, `âge × fumeur`, âge² centré. Encodage one-hot et standardisation pour les modèles linéaires, encodage ordinal sans mise à l'échelle pour les arbres. Cible log disponible avec correction de Duan (sans elle, exp(ŷ) estime une médiane, pas une moyenne).

Configuration (Ridge, CV 5 plis sur le train)	RMSE CV	R² CV
Ridge - variables brutes	6 297	0,723
Ridge - avec interactions	4 607	0,849
Ridge log (smearing) - variables brutes	9 745	0,341
Ridge log (smearing) - avec interactions	6 116	0,739
Ridge log (smearing) - interactions sans age_smoker	10 169	0,287
Ridge - interactions sans obese	4 591	0,850
Ridge - interactions sans smoker_obese	4 953	0,826
Ridge - interactions sans bmi_smoker	4 667	0,845
Ridge - interactions sans age_smoker	4 602	0,850
Ridge - interactions sans age_sq	4 657	0,846

Les interactions font passer la RMSE de 6 297 à 4 607 $. La cible log échoue ici : les coûts suivent des **bandes parallèles** (même pente d'âge en dollars pour tous), une structure additive qu'une échelle multiplicative déforme. L'interaction âge × fumeur corrige en partie ce biais.

5. Modélisation

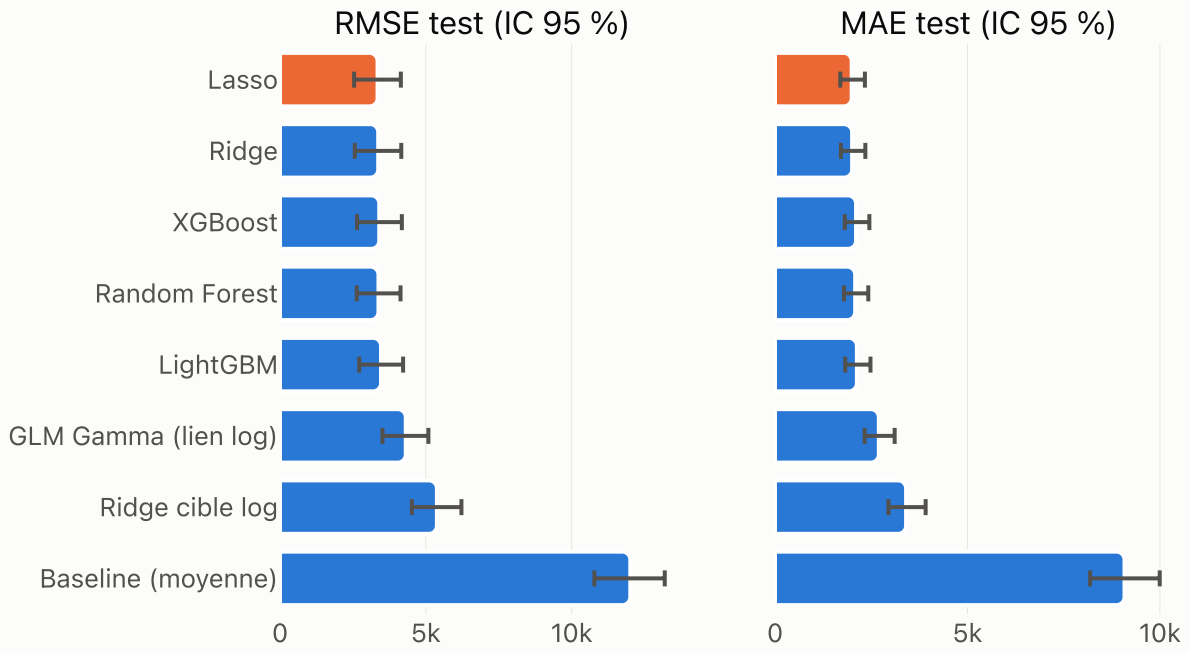
Protocole : split 80/20 stratifié sur le tabagisme (1069 / 268 assurés) ; hyperparamètres réglés en validation croisée 5 plis sur le train (grilles pour les modèles linéaires, recherche aléatoire pour les arbres) ; **sélection sur la RMSE de CV**, jamais sur le test ; évaluation finale unique sur le test avec IC 95 % bootstrap.

Modèle	Famille	RMSE CV	RMSE test [IC 95 %]	MAE test	R^2 test	Gini
Lasso ✓	**Linéaire**	**4 597 ± 684**	**3 345 [2 541 ; 4 144]**	**1 992**	**0,922**	**0,954**
Ridge	Linéaire	4 606 ± 681	3 368 [2 565 ; 4 159]	2 003	0,921	0,952
XGBoost	Boosting	4 704 ± 677	3 403 [2 643 ; 4 179]	2 106	0,920	0,950
Random Forest	Arbres	4 705 ± 659	3 376 [2 631 ; 4 133]	2 082	0,921	0,949
LightGBM	Boosting	4 717 ± 629	3 463 [2 716 ; 4 221]	2 127	0,917	0,947
GLM Gamma (lien log)	GLM actuariel	5 111 ± 537	4 313 [3 512 ; 5 088]	2 698	0,871	0,943
Ridge cible log	Linéaire	5 863 ± 415	5 381 [4 522 ; 6 222]	3 406	0,799	0,944
Baseline (moyenne)	Référence	12 098 ± 1 238	12 013 [10 781 ; 13 194]	9 081	-0,001	0,000

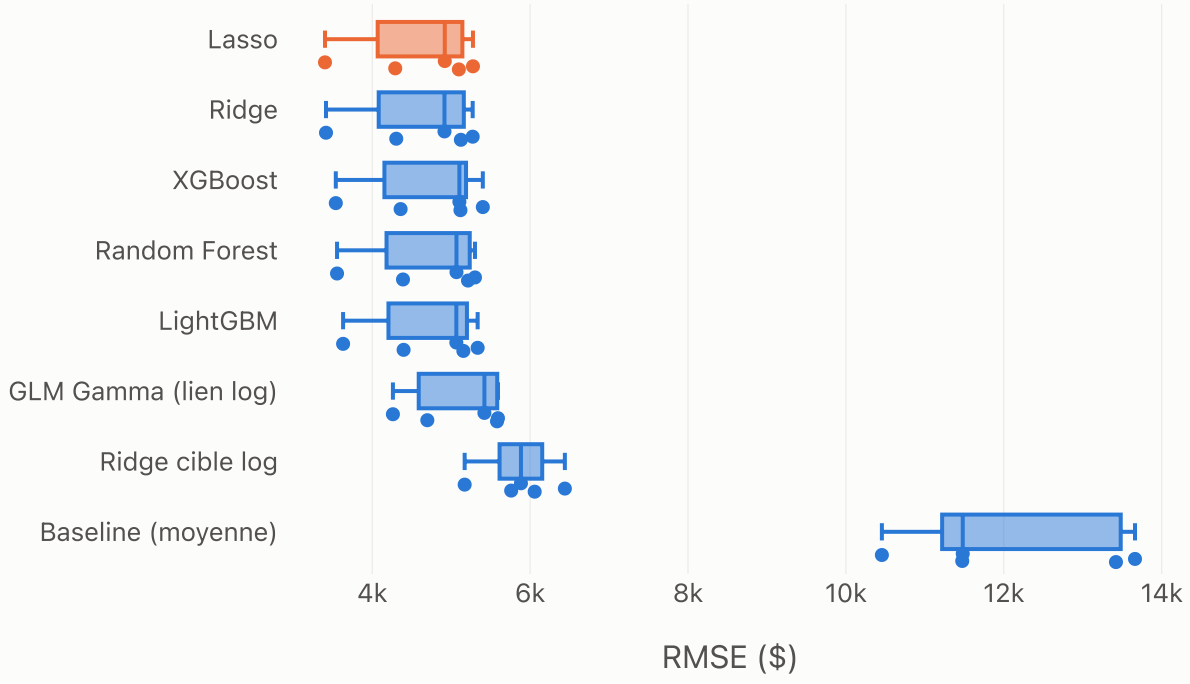
Gini normalisé : capacité à classer les risques (1 = ordre parfait). Calibration : Σ prédit / Σ observé (1 = portefeuille à l'équilibre).

> **Lasso vs Ridge** : écart de RMSE -23 $, IC 95 % bootstrap apparié [-51 ; 4]. Les meilleurs modèles sont **statistiquement à égalité** : leurs écarts de CV (≈ 100 $) sont bien inférieurs à la variabilité entre plis (≈ 684 $). On retient donc le plus simple et le plus auditable.

Comparaison des modèles, meilleur en CV : Lasso

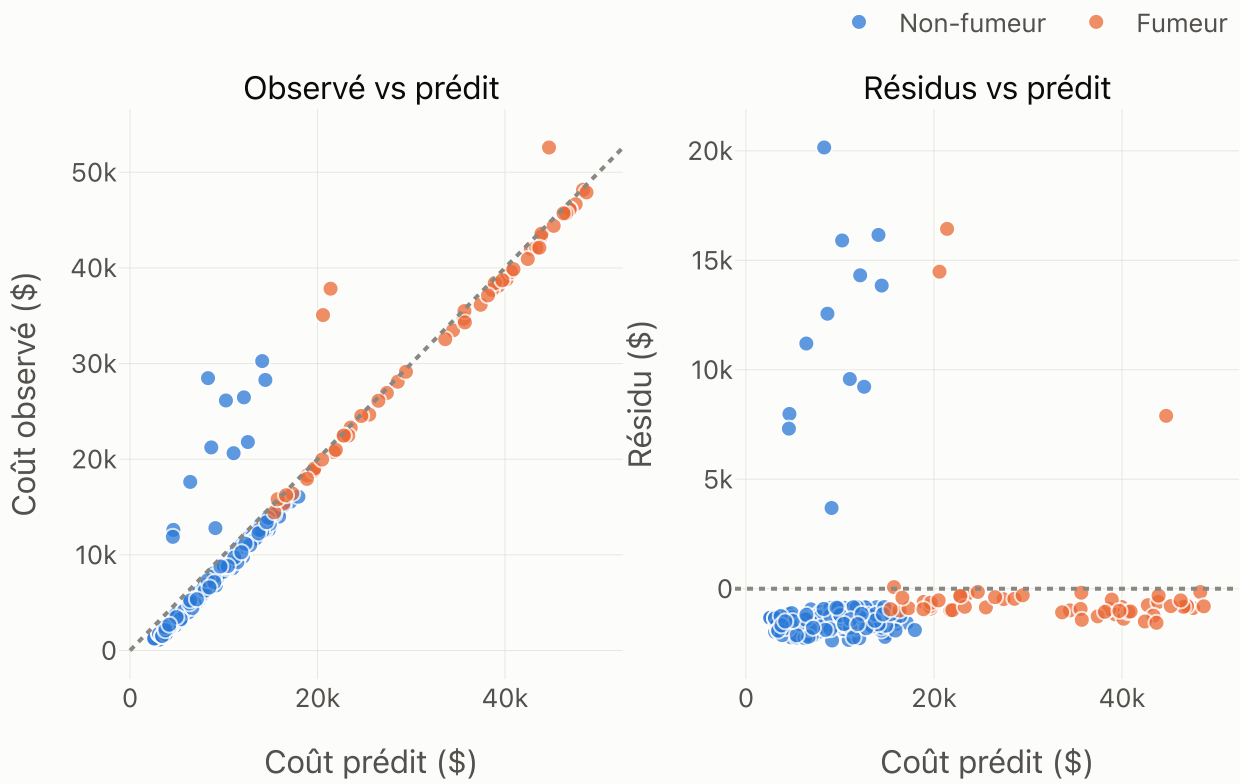


Stabilité : RMSE sur chacun des 5 plis de validation croisée



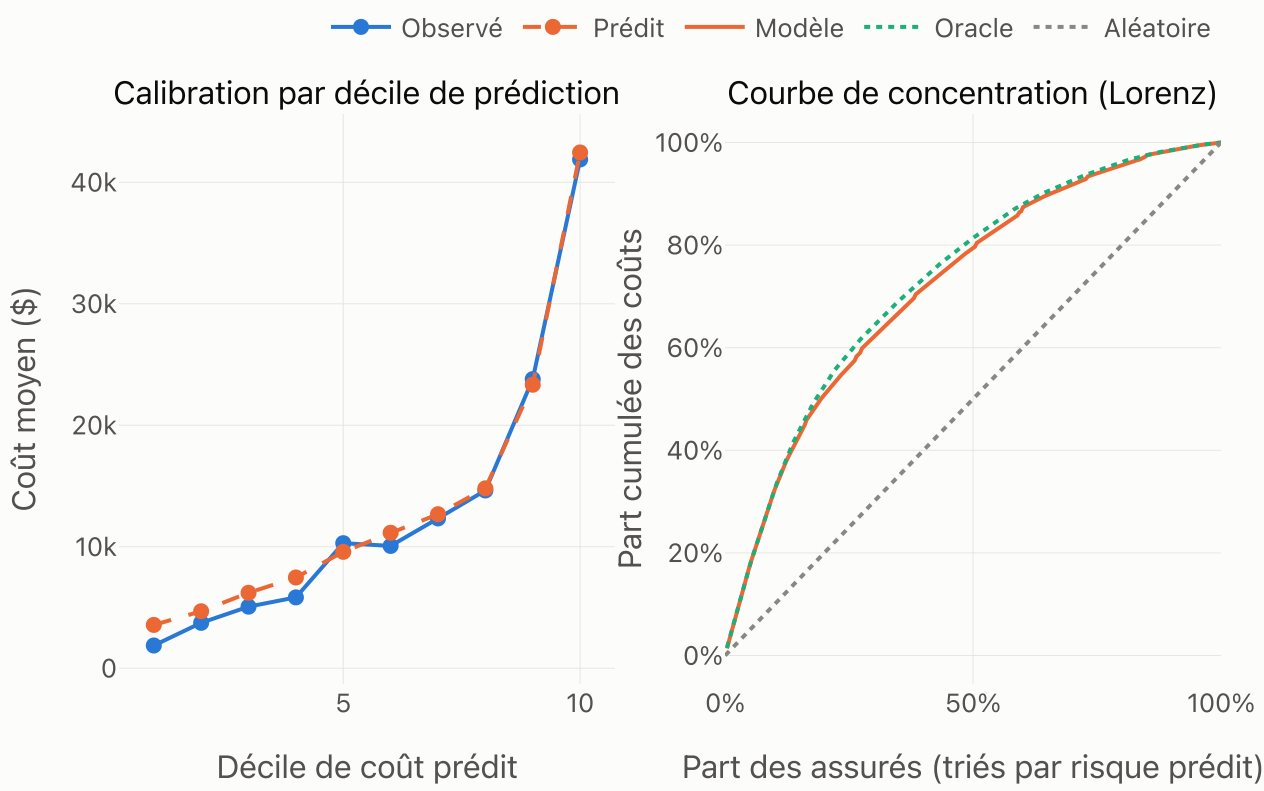
Analyse des résidus (Lasso)

Diagnostic des résidus : Lasso (jeu de test)



- **Deux régimes** : la plupart des assurés ont un résidu légèrement négatif (médiane -1 409 $), et 3,4 % ont un coût observé supérieur de plus de 10 000 $ à la prédiction. C'est le schéma « coût de base + choc occasionnel » : prédire l'*espérance* revient à faire payer à chacun une part du risque de choc, c'est la mutualisation.
- 78 % des grosses erreurs concernent des **non-fumeurs** : aucun des 6 facteurs n'explique leurs chocs. C'est le signal d'une variable manquante (antécédents médicaux).
- Asymétrie des résidus : 4,29 ; résidu moyen : -643 $.

Qualité actuarielle : calibration et pouvoir de segmentation



À gauche, observé et prédit se suivent du décile 5 au décile 10, où se concentre l'essentiel de la charge. Sur le décile le moins cher, le modèle prédit 3 564 $ pour 1 870 $ observés : les profils à bas risque (surtout jeunes non-fumeurs) sont surestimés, ce qui rejoint l'alerte d'équité. À droite, la courbe de concentration du modèle est quasi confondue avec celle de l'oracle : il ordonne presque parfaitement les risques (Gini 0,954).

Lecture actuarielle : relativités du GLM Gamma

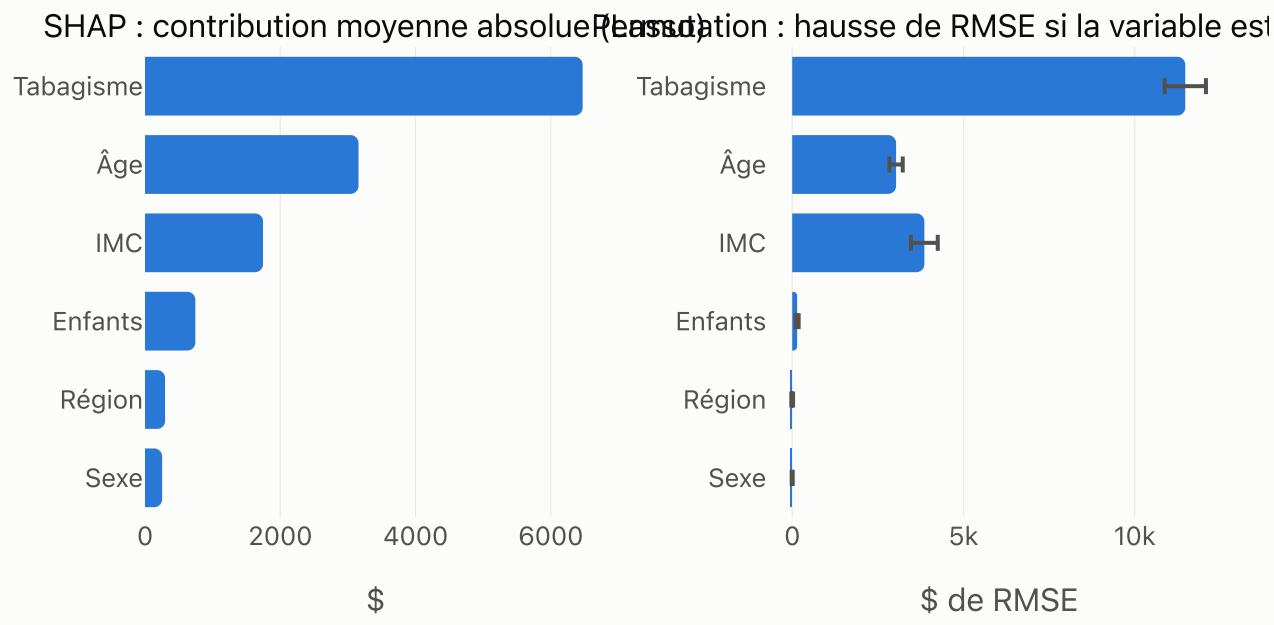
Coefficients exp(β) pour un écart-type de la variable (numériques) ou par rapport à la modalité de référence. Un facteur de 1,10 signifie +10 % sur le coût attendu, toutes choses égales par ailleurs. Coût de base : 8 741 $.

Variable	Relativité
smoker_yes	×4,223
age	×1,583
age_smoker	×0,658
bmi_smoker	×1,330
region_southwest	×0,819
smoker_obese	×1,156
region_southeast	×0,866
children	×1,124

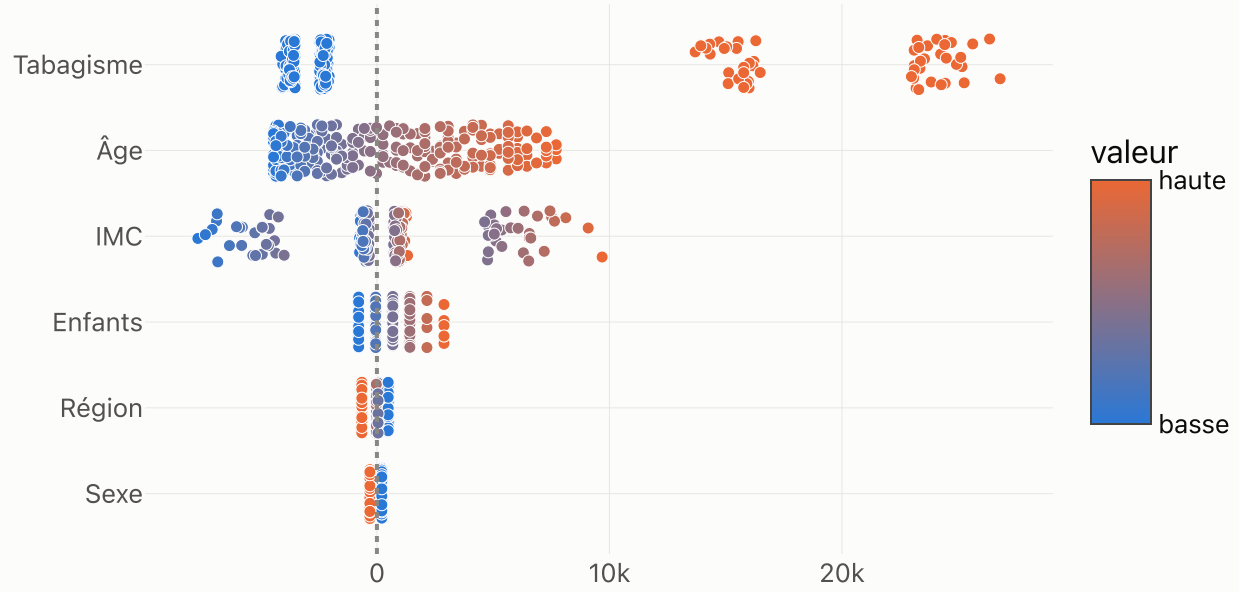
6. Interprétation et équité

- Hiérarchie (SHAP) : Tabagisme > Âge > IMC > Enfants > Région > Sexe. Le tabagisme pèse en moyenne 6 471 $ par assuré, l'âge 3 157 $, l'IMC 1 745 $; sexe et région moins de 298 $.
- Les modèles comparés s'accordent sur le top 3 : Lasso → Tabagisme, Âge, IMC; XGBoost → Tabagisme, Âge, IMC; GLM Gamma (lien log) → Tabagisme, Âge, IMC.
- Effet de seuil confirmé : passer d'un IMC de 28 à 32 ajoute 17 006 $ au coût prédit d'un fumeur contre 0 $ pour un non-fumeur.
- Équité : l'erreur absolue varie d'un facteur 1,76 entre tranches d'âge (max : 40-49), 1,18 entre sexes, 1,04 entre régions. Calibration (prédit / observé, 1,05 sur l'ensemble du test) : s'écartent significativement du niveau global : 18-29 1,17 [IC 1,11 ; 1,27], n = 79 ; fumeurs 1,00 [IC 0,97 ; 1,02], n = 55. C'est le point de vigilance équité : l'effet d'âge du modèle ne reproduit pas le niveau de coût de cette tranche. Pistes : recalibrer par tranche d'âge ou modéliser l'âge de façon non linéaire (spline). Les autres écarts restent dans le bruit d'échantillonnage.
- Tarification unisexe : neutraliser le sexe change la RMSE de -16 $ (3 329 $), un écart dans le bruit de validation. L'exigence réglementaire européenne ne coûte rien en précision.
- Contrôle technique : les contributions SHAP s'additionnent exactement à la prédiction (écart max 1,1e-10 $).

Importance des variables



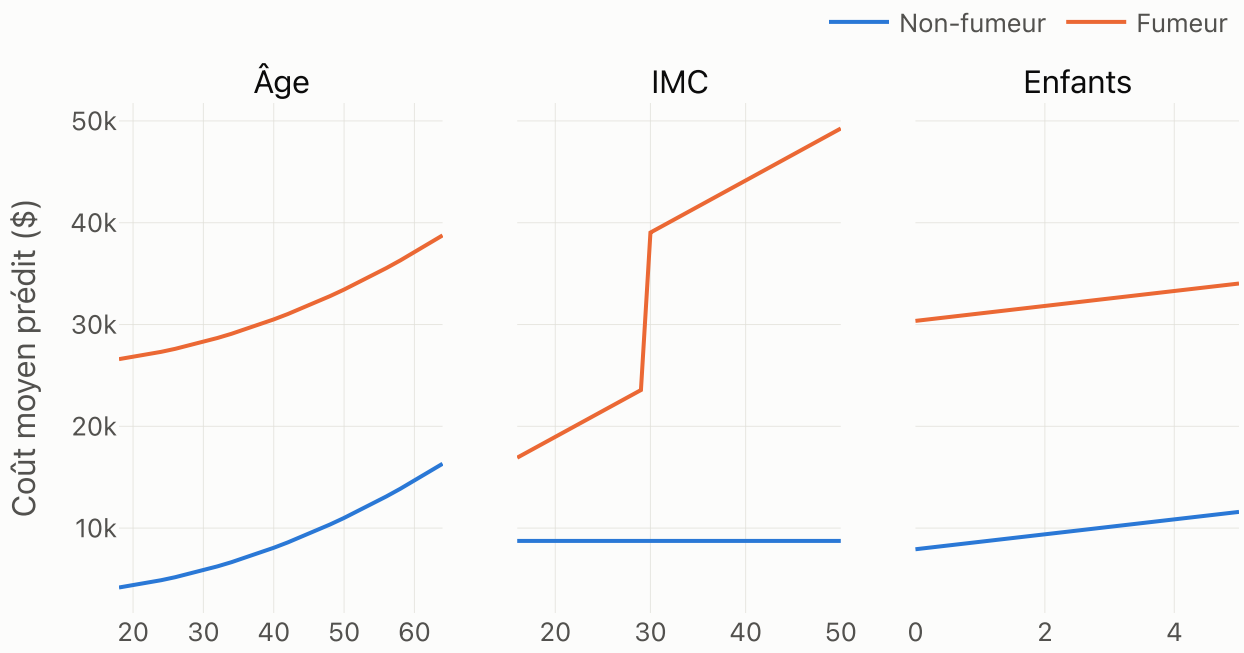
Valeurs SHAP par assuré (jeu de test)



Contribution à la prédiction ($)

Chaque point est un assuré du test. Sa position donne la contribution de la variable à sa prédiction (en $ par rapport au coût moyen prédit), sa couleur la valeur de la variable (orange = élevée / « oui »). Le tabagisme sépare deux nuages, l'âge s'étale de façon continue.

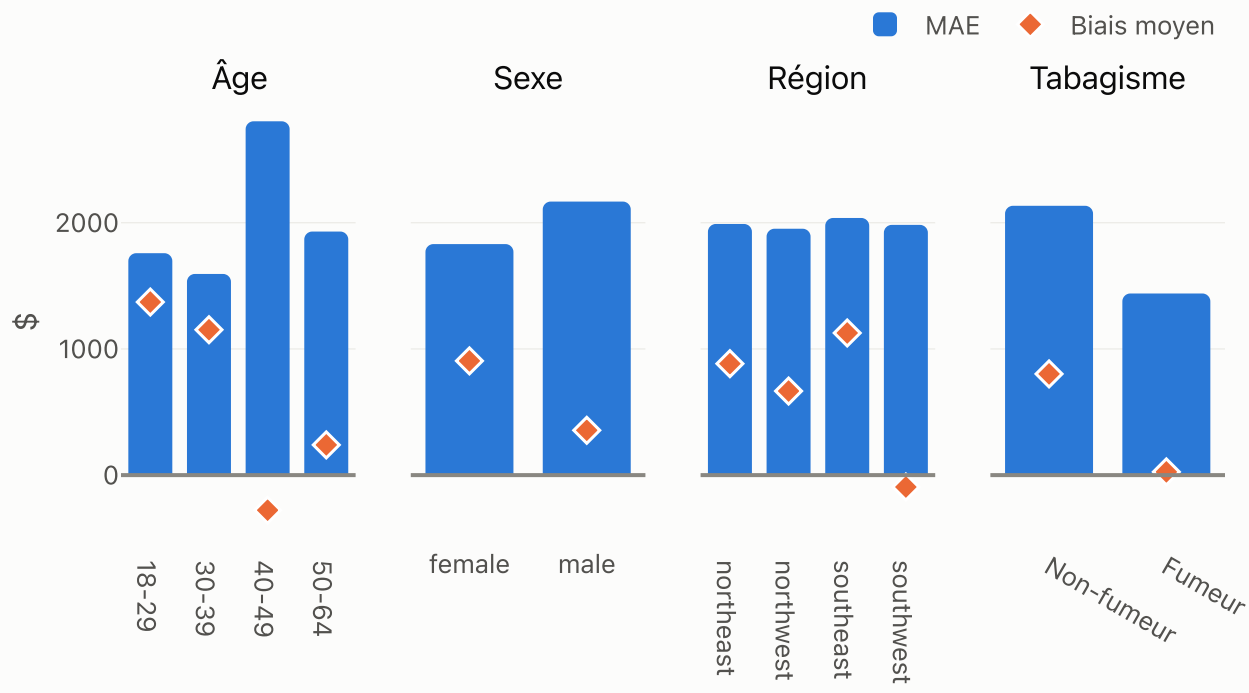
Dépendance partielle selon le tabagisme (Lasso)



Effet moyen d'une variable lorsque les autres restent à leurs valeurs observées, séparément pour fumeurs et non-fumeurs. Le saut d'IMC à 30 n'existe que chez les fumeurs.

Erreurs par sous-groupe

Équité : erreur absolue moyenne et biais (prédit – observé) par sous-groupe



Groupe	n	MAE	Biais moyen	Calibration [IC 95 %]
Âge : 18-29	79	1 759	1 372	1,17 [1,11 ; 1,27]
Âge : 30-39	51	1 594	1 152	1,10 [1,05 ; 1,16]
Âge : 40-49	54	2 804	-278	0,98 [0,88 ; 1,07]
Âge : 50-64	84	1 930	240	1,01 [0,97 ; 1,05]
Sexe : female	140	1 831	906	1,08 [1,03 ; 1,13]
Sexe : male	128	2 168	355	1,02 [0,98 ; 1,07]
Région : northeast	62	1 990	883	1,06 [1,00 ; 1,13]
Région : northwest	66	1 953	666	1,06 [0,98 ; 1,13]
Région : southeast	71	2 038	1 127	1,08 [1,03 ; 1,13]
Région : southwest	69	1 983	-94	0,99 [0,92 ; 1,07]
Fumeur : no	213	2 135	802	1,10 [1,04 ; 1,17]
Fumeur : yes	55	1 440	26	1,00 [0,97 ; 1,02]

Tarification unisexe : en neutralisant le sexe, la RMSE passe à 3 329 $ (-16 $). Respecter la jurisprudence européenne *Test-Achats* (2011) ne dégrade pas le modèle.

7. Limites

- **Données simulées et limitées** : 1 337 assurés, 6 variables, aucune dimension temporelle (inflation médicale, dérive), ni exposition, ni franchise. Les montants ne doivent pas être transposés à un portefeuille réel.
- **Associations, pas causalité** : le modèle ne dit pas combien un individu économiserait en arrêtant de fumer. Une étude causale (données longitudinales, appariement) serait nécessaire.
- **Coût total agrégé** : un actuaire séparerait fréquence et sévérité (modèle Poisson × Gamma, ou Tweedie) avec des données de sinistres individuels.
- **Test de taille modeste** (268 assurés) : les IC bootstrap le rappellent. Les conclusions d'équité sont des alertes à confirmer.
- **Variables sensibles** : le sexe est interdit en tarification dans l'UE, la région peut servir de proxy socio-économique, et l'IMC et le tabagisme sont des données de santé (RGPD, art. 9).

8. Recommandations métier

1. **Segmenter d'abord sur tabagisme × obésité, puis l'âge.** Trois segments (8 441 $ / 21 363 $ / 41 558 $) captent l'essentiel de l'hétérogénéité ; l'âge se tarife ensuite de façon quasi linéaire.
2. **Prévention ciblée** : les fumeurs obèses représentent 10,8 % des assurés mais coûtent en moyenne 33 117 $ de plus par an qu'un non-fumeur. C'est la cible prioritaire des programmes de sevrage et de nutrition, sous réserve d'une évaluation causale de leur efficacité.
3. **Déployer un modèle transparent** (Lasso), avec un challenger boosting suivi en parallèle. À performance égale, l'auditabilité prime (contrôle, explicabilité au client, régulateur).
4. **Collecter de quoi expliquer les chocs** : antécédents et pathologies chroniques, historique de sinistres. C'est le levier principal de gain de précision, devant le choix d'algorithme.
5. **Gouvernance et équité** : tarifer sans le sexe (coût nul), surveiller la calibration par tranche d'âge (jeunes surestimés), recalibrer le niveau global sur le portefeuille courant et suivre ces indicateurs à chaque mise à jour.

Annexe : reproductibilité

Ce rapport est régénéré de bout en bout par `make run` (CLI `insurance-costs run`) : téléchargement vérifié, audit, EDA, inférence, ablation, entraînement, interprétation, suivi MLflow puis rendu Jinja2. Seed 42 partout, dépendances épinglées, métriques identiques d'une exécution à l'autre.

Étape	Durée (s)
Chargement et vérification des données	0,0
Audit qualité et nettoyage	0,1
Analyse exploratoire	2,1
Statistiques inférentielles	1,8
Ablation du feature engineering	1,7
Entraînement et évaluation des modèles	45,3
Interprétation et équité	50,6
Suivi MLflow	4,1
Génération du rapport	0,5

Modèle publié : Lasso · hyperparamètres {'alpha': 46.41588833612777} · 2,1 Ko · scikit-learn 1.6.1 · Démonstration pédagogique. Ne pas utiliser pour une décision tarifaire ou médicale individuelle.

Fleury Niyokwizera · Code sous licence MIT · Données ODbL (Kaggle, *Medical Cost Personal Dataset*) · Dépôt GitHub